Estável não significa fiel: verificar explicações LIME antes de decidir

Tomás Gomes Ferreira

Mestrado em Inteligência Artificial
Departamento de Engenharia Informática, Universidade de Coimbra

Resumo

Avaliamos se as explicações LIME de um XGBoost treinado no Titanic reproduzem as previsões individuais. As explicações são intuitivas e, com 5000 amostras, estáveis, mas a *local prediction* afasta-se até 0,51 da probabilidade do modelo. Num passageiro, indica a classe oposta em 58 de 60 execuções com sementes e configurações diferentes, sem que o R^2 local ou a estabilidade o assinalem. A seleção de features muda sobretudo com a representação das variáveis contínuas. Propomos verificações em dois níveis: auditoria da configuração e verificação individual.

1 Questão e desenho experimental

Uma explicação LIME descreve um *local surrogate* linear, não o modelo [Ribeiro *et al.*, 2016]. Perguntamos **até que ponto esse substituto representa a decisão individual e o que verificar antes de confiar nele**. O modelo é um XGBoost [Chen and Guestrin, 2016] sem afinação (*accuracy* de 0,766 no teste, $n = 209$), adaptado de [Bhattacharya, 2022]. O explainer usa só o treino como referência, explica sempre `Survived=1`, trata `Pclass` como categórica e discretiza as contínuas por quartis (referência: 5000 amostras, top 5, *kernel width* 2,25). Medimos a *fidelity* pelo R^2 local, na vizinhança sintética, e pelo erro no ponto $|P - \hat{y}_{\text{loc}}|$. Analisamos 20 passageiros sorteados, os 13 de teste com $0{,}4 \leq P \leq 0{,}6$ (seleção intencional), o passageiro 1095 (caso de estudo, o de maior erro) e 60 candidatos ao SP-LIME. A análise é descritiva, sem testes de significância.

2 Quando a explicação não reproduz a previsão

As explicações da Tabela 1 são intuitivas. `Sex` tem o maior peso em todos os passageiros, seguida de `Pclass`, `Age` e `Embarked_C=0`. No top 3, `Sex` aparece 20 vezes, `Pclass` e `Embarked_C` 15, `Age` 9 e `Fare` 1, embora `Fare` entre em 12 dos top 5 com sinais mistos. Uma feature só ajuda uns passageiros e prejudica outros através de condições diferentes (`Pclass=1` $+0{,}24$; `Pclass=3` $-0{,}25$): o sinal de cada condição nunca muda.

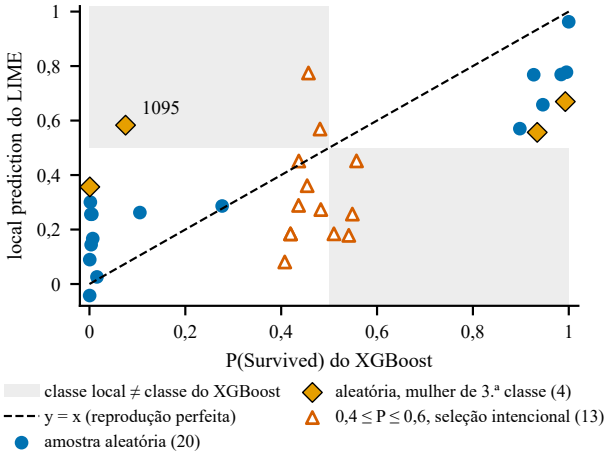


Figura 1: Probabilidade do XGBoost vs *local prediction* nos 33 passageiros explicados. Nas zonas sombreadas, o substituto indica a classe oposta. As quatro mulheres de 3.ª classe têm *local predictions* entre 0,36 e 0,67, embora o modelo lhes atribua probabilidades entre 0,001 e 0,993.

Intuitividade não é *fidelity*. O R^2 local varia pouco (0,376–0,491), mas o erro no ponto vai de 0,010 a 0,508, e as duas métricas têm pouca associação monotónica nesta amostra (Spearman 0,04). A Figura 1 mostra uma compressão para o centro: a *local prediction* fica acima de P em 9 dos 10 casos com $P \leq 0{,}1$ e abaixo nos 7 com $P \geq 0{,}9$. Por ser linear, pode até sair de $[0, 1]$ (759: $-0{,}042$).

No 1095, o XGBoost dá $P = 0{,}075$ e a *local prediction* é 0,583: o substituto indica a classe oposta, e o R^2 (0,457, o 13.º pior de 20) não o assinala. Os pesos descrevem um modelo que discorda do XGBoost; não os usaríamos como razão da previsão.

Nos 13 passageiros com $0{,}4 \leq P \leq 0{,}6$, a *fidelity* não é claramente pior do que nos 17 com probabilidade prevista extrema (R^2 mediano 0,445 e 0,443; erro mediano 0,235 e 0,218). O que muda é a consequência: a *local prediction* cruza 0,5 em 6 dos 13, contra 1 dos 17, em parte porque junto de 0,5 basta um erro pequeno. Os passageiros 241 e 46 têm a mesma P e a mesma explicação, mas desfechos opostos: *fidelity* ao modelo não é correção face à realidade.

ID	Perfil	P	Top 3 condições LIME (peso)	Intercept	*Local pred.*	R^2	$\lvert P - \hat{y}_{\text{loc}} \rvert$
759†	M3	0,0004	Sex=male (−0,49); Pclass=3 (−0,25); Embarked_C=0 (−0,11)	0,951	−0,042	0,454	0,043
838	M3	0,0006	Sex=male (−0,50); Pclass=3 (−0,24); Embarked_C=0 (−0,11)	0,888	0,090	0,458	0,089
1147	F3	0,0007	Sex=female (+0,49); Pclass=3 (−0,26); Age > 38.00 (−0,16)	0,490	0,356	0,491	0,356
445	M2	0,0019	Sex=male (−0,50); Age ≤ 21.00 (+0,12); Embarked_C=0 (−0,11)	0,746	0,301	0,386	0,299
566	M2	0,0029	Sex=male (−0,50); Embarked_C=0 (−0,11); Pclass=2 (+0,07)	0,760	0,256	0,376	0,253
509†	M2	0,0035	Sex=male (−0,50); Age > 38.00 (−0,16); Embarked_C=0 (−0,11)	0,773	0,144	0,404	0,141
422	M2	0,0050	Sex=male (−0,50); Embarked_C=0 (−0,11); Pclass=2 (+0,07)	0,760	0,256	0,376	0,251
751	M3	0,0068	Sex=male (−0,50); Pclass=3 (−0,24); Embarked_C=0 (−0,11)	0,838	0,167	0,462	0,160
1184	M3	0,0156	Sex=male (−0,50); Pclass=3 (−0,24); Age > 38.00 (−0,16)	0,919	0,026	0,486	0,010
1095	F3	0,0753	Sex=female (+0,50); Pclass=3 (−0,25); Embarked_C=0 (−0,11)	0,309	0,583	0,457	0,508
307†	M1	0,1052	Sex=male (−0,51); Pclass=1 (+0,24); Age > 38.00 (−0,15)	0,728	0,262	0,460	0,157
61	M1	0,2768	Sex=male (−0,51); Pclass=1 (+0,24); Embarked_C=0 (−0,11)	0,757	0,286	0,436	0,010
584	F2	0,8979	Sex=female (+0,50); Age > 38.00 (−0,16); Embarked_C=0 (−0,10)	0,332	0,570	0,414	0,328
600	F2	0,9269	Sex=female (+0,50); Embarked_C=0 (−0,11); Pclass=2 (+0,09)	0,253	0,768	0,385	0,159
1190†	F3	0,9342	Sex=female (+0,49); Pclass=3 (−0,26); Age ≤ 21.00 (+0,11)	0,422	0,557	0,473	0,377
472	F2	0,9459	Sex=female (+0,50); Age > 38.00 (−0,16); Embarked_C=0 (−0,10)	0,267	0,658	0,412	0,288
585	F2	0,9841	Sex=female (+0,50); Embarked_C=0 (−0,11); Pclass=2 (+0,09)	0,251	0,769	0,386	0,215
1224	F3	0,9928	Sex=female (+0,50); Pclass=3 (−0,25); Fare ≤ 8.05 (+0,12)	0,340	0,670	0,477	0,323
592	F2	0,9952	Sex=female (+0,49); Age ≤ 21.00 (+0,12); Embarked_C=0 (−0,11)	0,259	0,777	0,393	0,218
320†	F1	0,9999	Sex=female (+0,51); Pclass=1 (+0,24); Embarked_C=1 (+0,10)	0,085	0,963	0,443	0,037

Tabela 1: Os 20 passageiros sorteados (Atividades 1–2), por ordem de P(Survived). Perfil: sexo e classe. †: os 5 comparados primeiro. O R^2 quase não varia, mas o erro vai de 0,010 a 0,508; no 1095 (negrito), a *local prediction* fica do lado oposto de 0,5.

`num_samples` (seleções em 10)	Ocasionais	`Sex=female` média [mín; máx]	J	Erro
500	Emb_Q 3, Emb_S 3, Fare 2, Parch 2	0,49 [0,44; 0,53]	0,73	0,48
1000	SibSp 9, Parch 6, Fare 2, Age 1, Emb_Q 1, Emb_S 1	0,48 [0,45; 0,51]	0,72	0,49
5000	Emb_Q 6, Parch 4	0,49 [0,46; 0,51]	0,82	0,49

Tabela 2: Passageiro 1095 com 10 sementes por `num_samples`. `Sex`, `Pclass` e `Embarked_C` são sempre selecionadas (e `SibSp`, exceto 9/10 com 1000). J: Jaccard médio dos 45 pares de sementes. Erro: $\lvert P - \hat{y}_{\text{loc}} \rvert$ médio. A amplitude mediana dos pesos desce de 0,083 para 0,060 e 0,035, mas o erro não diminui.

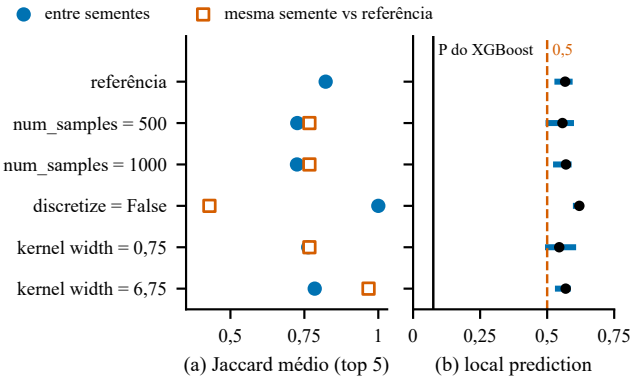


Figura 2: Passageiro 1095, um fator de cada vez, com 10 sementes por variante. (a) Só sem discretização a concordância com a referência fica abaixo do mínimo observado entre sementes. (b) A *local prediction* fica quase sempre acima de 0,5, longe de $P = 0{,}075$ (traço: mín–máx; ponto: média).

Nesta amostra, os maiores erros concentram-se num perfil: as quatro mulheres de 3.ª classe sorteadas estão entre os cinco maiores erros, embora tenham o R^2 mediano mais alto (0,475). O modelo coloca-as nos dois extremos, mas o substituto atribui-lhes coeficientes quase iguais de `Sex` e `Pclass` (Figura 1). Com $n = 4$, isto é exploratório e não evidencia falha sistemática nem um problema de *fairness*.

3 Estabilidade, localidade e representação

Com 10 sementes por valor de `num_samples` (Tabela 2), mais amostras estabilizam os pesos do 1095 e, com 5000, também a seleção. Os sinais só mudam com 500 amostras, em features raramente selecionadas. O custo adicional é de centésimas de segundo (cerca de 22%). O erro médio, porém, fica em 0,48–0,49: a explicação torna-se **mais reprodutível sem se tornar mais fiel**.

Alterando um fator de cada vez, com as mesmas sementes da referência (Figura 2), só a representação produziu uma mudança clara: sem discretização, o Jaccard emparelhado (0,43) fica abaixo do mínimo entre sementes (0,67), porque `Age` e `Fare` entram e `SibSp` sai. Com `num_samples` e *kernel width* 0,75, as diferenças (0,77) têm magnitude semelhante à variabilidade entre sementes; com 6,75, a seleção quase não muda (0,97). A *local prediction* fica do lado oposto de 0,5 em 58 das 60 execuções, e a variante mais estável (`False`) tem o maior erro (0,54). Nos 20 passageiros, mudar a representação alterou a seleção mais do que mudar a semente em 16 casos. A estabilidade tem associação fraca com o erro nesta amostra (Spearman 0,18), e o passageiro de menor erro (61) é menos estável do que o 1095: **estabilidade não garante *fidelity***.

Porque se parecem tanto as explicações? Com a mesma

Grupo	n	Cond.	Obj.	%M	%1.ª	P med.	$P \leq 0{,}1$
Teste	209	–	–	68	31	0,24	93
Candidatos	60	16	1	65	22	0,21	26
SP $k = 3$ (ambas)	3	12	0,91	33	33	0,88	1
SP $k = 5$, s123	5	15	0,99	20	60	1,00	1
SP $k = 5$, s7	5	15	0,99	20	40	0,98	1

Tabela 3: SP-LIME com 60 candidatos e as sementes 123 e 7. Cond.: condições cobertas (de 16). Obj.: fração do objetivo do SP-LIME coberta. %M: homens. %1.ª: 1.ª classe.

semente, as perturbações são idênticas para todos os passageiros, e o kernel, calculado sobre nove indicadores binários, nunca atribui peso inferior a 0,41. Nas 200 explicações anteriores, o coeficiente de uma mesma condição variou menos entre passageiros do que entre sementes em 5 de 7 condições (`Sex=female`: amplitude 0,020 contra 0,045). Isto sugere uma **localidade fraca** nesta configuração, que poderia contribuir para a indiferenciação das mulheres de 3.ª classe. Não é uma prova: a distribuição real das distâncias não foi medida, e reduzir a *kernel width* para 0,75 não baixou claramente o erro do 1095.

A representação muda também o significado dos números. Com `True`, o coeficiente de `Age` ou `Fare` é o efeito de pertencer a um intervalo (`28<Age<=38`: $+0{,}016$; `8.05<Fare<=15.02`: $+0{,}026$); com `False`, é uma inclinação por desvio-padrão (`Age`: $-0{,}073$ por 14,4 anos), e o contributo é o coeficiente $\times\, z$. Para `Fare` $= 8{,}68$ ($z = -0{,}49$), o coeficiente é $-0{,}066$, mas o **contributo é positivo** ($+0{,}032$), tal como em `SibSp` e `Parch`: ler a barra como efeito neste passageiro inverteria o sinal. O erro no ponto quase não muda (0,534 e 0,542).

4 Cobertura e plausibilidade

O SP-LIME maximiza a cobertura ponderada das condições. Com $k = 3$, ambas as sementes escolhem 1184, 45 e 583 (um homem de 3.ª classe, uma mulher de 1.ª e uma rapariga de 2.ª), com condições diferentes nas explicações. Com $k = 5$, juntam-se o 215 e o 310 (semente 123) ou o 441 (semente 7), e ficam cobertas as 8 features presentes nas candidatas (6 com $k = 3$). Os dois passageiros extra acrescentam só 0,055 e 0,028 ao objetivo, e a semente muda apenas o quinto. A Tabela 3 mostra que cobertura não é representatividade: neste conjunto, 20% são homens (68% no teste), a probabilidade mediana é próxima de 1 e nenhum está na faixa 0,4–0,6. Nenhuma das cinco explicações cruza 0,5, mas o critério não usa *fidelity*, e o 441 tem erro 0,326. Usado como retrato do sistema, este conjunto omite os perfis atípicos e os casos difíceis.

Na experiência adicional, capturámos as perturbações enviadas ao XGBoost (Figura 3). Com discretização, 50,3% violam pelo menos uma restrição do domínio, sobretudo por terem zero ou mais de um porto de embarque; sem discretização, 100% violam pelo menos uma das restrições avaliadas. O substituto é, assim, ajustado a respostas do modelo em perfis impossíveis. Isto revela um problema de plausibilidade, mas, sem comparação com vizinhanças restritas a perfis válidos, não mostra que seja a causa do erro.

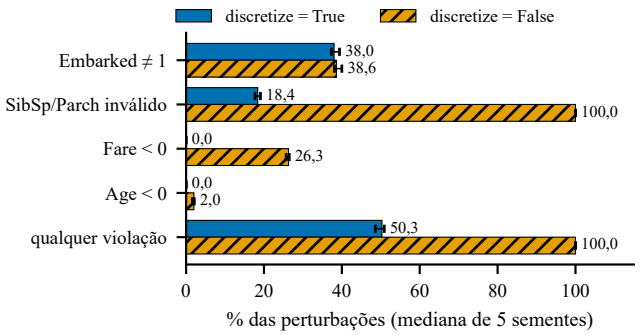


Figura 3: Perturbações sintéticas que violam restrições do domínio (barras de erro: mín–máx das 5 sementes). A discretização elimina os valores negativos, mas não os indicadores de porto inconsistentes, sorteados de forma independente.

5 Implicações práticas e conclusão

Nesta configuração, as explicações são intuitivas e, com amostras suficientes, reprodutíveis, mas **a estabilidade e um R^2 local razoável não garantiram fidelidade no ponto explicado**: coeficientes quase iguais de `Sex` e `Pclass` acompanham $P = 0{,}001$ e $P = 0{,}993$. Para o mesmo passageiro, a explicação muda sem que a previsão mude porque o substituto depende da amostragem, da representação e do kernel. Propomos dois níveis de verificação antes de mostrar uma explicação a quem decide.

Auditoria da configuração, feita uma vez: representação adequada de cada variável; plausibilidade das perturbações; sensibilidade à representação, a `num_samples` e à *kernel width*; *fidelity* e *stability* em casos de referência, incluindo casos difíceis e com P perto de 0,5.

Verificação individual, em cada explicação: desacordo entre P e a *local prediction*, incluindo o lado do limiar; R^2 local; estabilidade entre sementes, quando a decisão o justificar; e comunicação da explicação como descrição de um substituto, com a configuração e estas métricas.

Os dois níveis complementam-se: com a mesma configuração, o erro variou entre 0,01 e 0,51 entre passageiros. Estes resultados referem-se a um modelo, a um conjunto de dados e a amostras pequenas, uma delas selecionada.

Referências

[Bhattacharya, 2022] Aditya Bhattacharya. *Applied Machine Learning Explainability Techniques*. Packt Publishing, 2022.

[Chen and Guestrin, 2016] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.

[Ribeiro *et al.*, 2016] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. "Why should I trust you?": Explaining the predictions of any classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1135–1144, 2016.